

Explicabilidad en capas (Ciudadano vs. Regulador)

Prioritarla

EIA - Anexo de Explicabilidad en capas

Índice

A. Capa 1: Diagrama de explicabilidad para usuarios finales (Ciudadanos)	3
1. Información de transparencia y uso de la IA	3
2. Entrada de datos	3
3. El Motor de PrioritarIA	3
4. Salida	3
5. Supervisión humana y derechos	4
B. Capa 2: Diagrama de explicabilidad para auditoría y reguladores (AEPD, AESIA)	4
1. Fuentes de datos	4
2. Modelo algorítmico	5
3. Interfaz y transparencia (outputs)	5
4. Control y trazabilidad	5
Referencias	7

A. Capa 1: Diagrama de explicabilidad para usuarios finales (Ciudadanos)

En esta sección vamos a traducir las obligaciones de transparencia de la Ley Europea de IA a una interfaz accesible visualmente, garantizando los derechos del solicitante sin abrumarlo con la complejidad técnica del algoritmo ni agravar la brecha digital.

1. Información de transparencia y uso de la IA

Antes de que el usuario introduzca cualquier dato, la interfaz muestra una notificación de transparencia para cumplir con los requisitos de información dictados por la Ley Europea de IA para sistemas de alto riesgo [2]. Este aviso explica al usuario de forma clara y sencilla que PrioritarIA es una herramienta de asistencia que calculará su urgencia para asignarle una posición de forma justa en las colas de la ayuda solicitada. Además, dejamos claro desde el principio que el sistema “no decide de forma autónoma” y que no descarta a nadie automáticamente.

2. Entrada de datos

El ciudadano aporta su documentación básica (DNI/NIE, certificados bancarios, justificantes de necesidad, acreditación de discapacidad, etc.) [3] . Esta información se complementa de forma automática y segura con los registros del Ayuntamiento y de otras administraciones para configurar su perfil de vulnerabilidad sin que tenga que presentar los mismos papeles repetidas veces.

Además, se podrá aportar mediante un formulario digital oficial o de forma presencial con la asistencia de un profesional cualificado, para así evitar la brecha digital.

3. El Motor de PrioritarIA

En lugar de ser una “caja negra” opaca e incomprensible en la que el usuario no conozca nada sobre por qué se le ha asignado un puesto en la cola de prioridad, la interfaz del sistema explica que realiza un “Cálculo de Urgencia Real”. Se le informa de manera clara y visual que la plataforma evalúa su nivel de necesidad actual, reordenando las solicitudes en base a urgencia y no por un simple orden de llegada.

4. Salida

El sistema asigna y muestra al ciudadano una posición en una lista de espera independiente y específica para el programa específico que ha solicitado (como por ejemplo, una cola exclusiva para becas de comedor). Se le muestra su lugar en el ranking de esa ayuda concreta, dejando claro que el sistema no mezcla todas las solicitudes en una sola lista universal, así evitando comparaciones confusas y subjetivas con otras ayudas de muy distinta naturaleza.

5. Supervisión humana y derechos

Para materializar el derecho a una explicación y a la intervención humana exigido por la Ley Europea de IA [2], la interfaz incluye un aviso destacado garantizando que el algoritmo

no decide solo (por ejemplo: "¡La máquina no decide sola!"). De esta manera, se informa al usuario que la resolución final siempre es revisada y firmada por una persona responsable trabajadora del ayuntamiento. Asimismo, se le informa de su derecho a solicitar una explicación comprensible sobre cómo se ha calculado su posición en la lista, cumpliendo con las normativas de sistemas de alto riesgo de la Ley Europea de IA.

Por otro lado, si el ciudadano no está de acuerdo o cree que el sistema no ha captado una circunstancia excepcional, dispone de un canal de acción directo. Para ello, la interfaz incluye un botón de "Solicitar revisión por un trabajador social", para que un humano revise el caso y, si está justificado, altere su posición en el ranking.

B. Capa 2: Diagrama de explicabilidad para auditoría y reguladores (AEPD, AESIA)

En esta sección, vamos a detallar el flujo técnico de datos, el funcionamiento del algoritmo y el cumplimiento de las normativas exigidas para un sistema de alto riesgo.

1. Fuentes de datos

- **Gobernanza y Calidad de Datos (Art. 10 EU AI Act) [1]:** al ser PrioritarIA un sistema de alto riesgo, los datos procesados deben ser exactos, representativos, actualizados y sin sesgos. La toma de datos se realiza directamente a través del **formulario oficial de solicitud** cumplimentado por la ciudadanía. Para dar cumplimiento al Art. 10 y evitar errores en la declaración manual, el sistema integra mecanismos de validación de formato y contraste documental con las fuentes aportadas por la persona solicitante.
- **Protección de datos sensibles y sesgos (Art. 10.5 EU AI Act) [1]:** por regla general, el RGPD prohíbe el procesamiento de datos especialmente protegidos (origen étnico, religión u orientación política). En PrioritarIA, estas variables quedan totalmente excluidas del formulario de solicitud. Siguiendo la excepción técnica prevista en el Artículo 10.5 de la Ley de IA, únicamente se recogen en el formulario datos objetivos de salud o grado de dependencia declarados y acreditados como ponderadores de vulnerabilidad social, garantizando además que estos datos solo se utilicen para monitorizar, detectar y corregir posibles sesgos algorítmicos hacia colectivos desfavorecidos.
- **Aplicación del RGPD y Privacidad desde el Diseño (Mapa de Referencia AEPD) [3]:** siguiendo las directrices del Mapa de Referencia de la AEPD (Junio 2025), PrioritarIA incorpora la Guía de Privacidad desde el Diseño y la Protección de Datos por Defecto desde las fases iniciales del desarrollo, además de someterse a una Evaluación de Impacto en Tratamientos de Datos Personales (EIPD). En la práctica, una vez que el ciudadano envía el formulario, sus datos se seudonimizan mediante un identificador único no reversible (*hash*) antes de ser procesados por el motor de cálculo, garantizando el principio de minimización y evitando que el sistema opere con identidades reales (nombres o DNI) durante la fase de priorización.

2. Modelo algorítmico

- **Transparencia en Decisiones Automatizadas y Perfilado (AEPD) [3]:** siguiendo las directrices del Mapa de Referencia de la AEPD sobre decisiones automatizadas y perfilado, PrioritarIA no utiliza modelos de aprendizaje automático opacos (cajas negras) ni IA generativa para asignar las ayudas sociales. En su lugar, implementa un sistema híbrido determinista: primero aplica un filtro estricto de reglas normativas para comprobar los requisitos legales y después, un modelo de puntuación multicriterio totalmente transparente que asigna puntos en función de criterios objetivos aprobados públicamente.
- **Explicabilidad Técnica mediante valores SHAP (XAI):** para evitar el problema de la caja negra en las evaluaciones, el sistema incorpora un motor de explicabilidad basado en valores SHAP. Esta herramienta técnica desglosa con precisión la contribución de cada variable (ingresos, cargas familiares, grado de dependencia) en la nota final de cada expediente. De este modo, un auditor o regulador puede verificar exactamente qué factores sumaron o restaron puntos en la decisión y en qué proporción.
- **Mecanismo de Equidad y Antiestancamiento (Anti-Starvation):** para evitar que los expedientes de menor puntuación queden relegados indefinidamente en la cola por la entrada constante de nuevos casos de alta vulnerabilidad, el sistema incorpora un factor dinámico de ponderación por antigüedad. Este corrector sumará puntos de manera progresiva en función del tiempo acumulado en la lista de espera, lo cual garantiza cuantitativamente la equidad funcional del sistema y asegura que ningún expediente se quede bloqueado o desatendido durante un largo periodo.

3. Interfaz y transparencia (outputs)

- **Informe Técnico de Auditorías de IA (AEPD) [3]:** en base a los criterios del bloque de Auditoría del mapa de referencia de la AEPD, el sistema genera de forma automática un informe técnico de salida estructurado por cada solicitud procesada. Este documento incluirá la puntuación global asignada, el desglose detallado de puntuaciones parciales, el vector de atribución técnica SHAP (que justifica cada variable) y la verificación automática de los requisitos legales de elegibilidad.
- **Interfaz de Control para Empleados Públicos (GUI Municipal):** el sistema dispone de una vista específica en el cuadro de mando municipal diseñada para los trabajadores sociales. En esta interfaz no se muestra únicamente la nota final, sino una representación gráfica intuitiva del árbol de decisión algorítmico y los valores SHAP del expediente. Esto permite al personal técnico comprender rápidamente el razonamiento del sistema, detectar cualquier anomalía y disponer de toda la información justificada antes de validar la resolución.

4. Control y trazabilidad

- **Trazabilidad y Registros inmutables (Audit Logs) [3]:** siguiendo las directrices de auditoría de la AEPD, cada ejecución del sistema genera un registro de auditoría (log) inmutable y firmado digitalmente. En este registro se almacena la versión exacta del modelo algorítmico utilizado, la fecha y la hora, los datos de entrada

seudónimos y la recomendación emitida. Esto garantiza la trazabilidad completa e impide cualquier modificación manual o no autorizada.

- **Supervisión Humana Efectiva (Art. 14 EU AI Act) [2]:** cumpliendo el principio de supervisión humana, PrioritarIA está diseñado para que la propuesta de priorización generada por el algoritmo sea únicamente un dictamen técnico no vinculante. El sistema requiere de forma obligatoria la revisión, validación y firma de un trabajador social o funcionario público antes de que la resolución se convierta en una decisión administrativa formal.
- **Evaluación de Impacto en Derechos Fundamentales (Metodología HUDERIA - AEPD) [3]:** aplicado a la metodología HUDERIA respaldada por AEPD para la evaluación de riesgos en IA, el sistema se somete a auditorías periódicas ex-post. Mediante el análisis de métricas de impacto diferencial se verifica de forma continua que el algoritmo no genere sesgos sistemáticos hacia ningún colectivo protegido o desfavorecido.

Referencias

1. **Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo (EU AI Act):** *Artículo 10 (Gobernanza de datos).*
<https://artificialintelligenceact.eu/es/article/10/>
2. **Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo (EU AI Act):** *Artículo 14 (Supervisión Humana).*
<https://artificialintelligenceact.eu/es/article/14/>
3. **Agencia Española de Protección de Datos (AEPD):** *Mapa de Referencia para Tratamientos que incluyen Inteligencia Artificial (Junio 2025).*
<https://www.aepd.es/infografias/tratamientos-inteligencia-artificial.pdf>