Sprint 2 - PrioritarIA

1. Qué es nuevo en este sprint

En este segundo sprint profundizamos en la definición de PrioritarIA abordando las críticas éticas, técnicas y regulatorias que recibimos en el debate del Sprint 1 (Especificación v2.0, Apéndice A). Además, hemos diseñado prototipos de baja fidelidad del flujo y de la interfaz (Apéndice B) y hemos trabajado los siguientes desafíos éticos: personalización (Apéndice C), explicabilidad en capas (Apéndice D), posturas macro (Apéndice E), robustez con 10 casos límite (Apéndice F) y riesgos a gran escala (Apéndice G).

El objetivo del sistema no cambia: reordenar por urgencia real, y no por orden de llegada, las colas de las ayudas sociales de un ayuntamiento, con una cola independiente por programa y con la decisión final siempre en manos de una persona.

2. Evolución de la especificación y respuesta al debate

En el debate nos atacaron sobre todo por justificar el sistema solo con que "el humano es el responsable final". Estos son los cambios principales de la v2.0 para que no nos puedan atacar por el mismo lado:

• Métricas objetivas: de calidad (correcciones del trabajador social, tiempo de espera de los casos más urgentes), de equidad (por nacionalidad, tipo de hogar, zona y canal) y de procedimiento (reclamaciones).

• Filtro normativo previo: el sistema comprueba primero los requisitos legales y sólo después calcula la puntuación de urgencia.

• Mecanismo anti-estancamiento: la antigüedad en la lista suma puntos hasta un tope y, si se supera el plazo máximo, el caso pasa a revisión humana.

• Supervisión real: revisión obligatoria de los casos dudosos (datos incompletos, baja confianza, cambios bruscos de posición) y muestra aleatoria mensual. • Datos históricos auditados: la urgencia se define con criterios explícitos y el aprendizaje solo ajusta los pesos dentro de límites aprobados.

• Acceso multicanal y transparencia: canal web, telefónico asistido y presencial con el mismo peso; los datos que faltan nunca bajan la urgencia; derecho a explicación individual sin tener que reclamar antes, y los casos de riesgo vital salen de la cola hacia el protocolo de emergencias.

3. Prototipos y Arquitectura (Mock-ups)

El Apéndice B baja el sistema a tierra con un flujo de tres pasos. En la entrada, el ciudadano pide la ayuda por la web municipal o por un canal telefónico asistido pensado para personas mayores o sin internet. El motor recoge los datos básicos, calcula un orden de urgencia (no aprueba ni deniega nada) y genera una nota que explica la posición; si faltan datos o el caso es confuso, lo marca con un aviso de duda. En el destino, el trabajador social ve listas separadas por ayuda, ya ordenadas por gravedad, y tiene la última palabra.

Hemos hecho cuatro prototipos low-fi: el formulario web paso a paso, el esquema del canal telefónico, la cola de trabajo del empleado municipal y la ficha individual del caso, donde se ve por qué la IA propone esa urgencia y se toma la decisión.

4. Profundización en Desafíos Éticos

Riesgos a gran escala (Apéndice G). Con cientos de millones de usuarios, un error del 1% afectaría a millones de personas. Los principales riesgos son la amplificación de sesgos, la propagación de errores entre programas (el perfil de vulnerabilidad se reutiliza), la manipulación estratégica, la exclusión acumulativa por brecha digital, la dependencia excesiva del ranking por parte de los trabajadores y las filtraciones de datos muy sensibles. Salen ganando las personas con necesidades urgentes y las administraciones; pueden salir perdiendo quienes sufren errores, sesgos o problemas de documentación.

Posturas macro (Apéndice E). El grupo estaba repartido a partes iguales entre aceleracionistas, safetyistas y escépticas. La organización defiende una postura escéptica con matices safetyistas: la eficiencia no puede conseguirse a costa de quien está en desventaja. Esto se traduce en auditorías de sesgos, métricas de equidad, canales no digitales, revisión humana y derecho a explicación.

Personalización y sus límites (Apéndice C). El sistema no se adapta a gustos, sino al perfil de vulnerabilidad, y la posición varía según la ayuda pedida. Ponemos tres límites: frente al gaming, solo cuentan datos verificables y firma una persona; frente a la brecha digital, el perfil se puede construir de forma presencial; y nunca se crea un "perfil de urgencia universal" que compare necesidades de distinta naturaleza.

Robustez: 10 casos límite (Apéndice F). Hemos intentado romper el sistema con casos de ambigüedad, desactualización, sesgos y manipulación, incluido un intento de prompt injection con texto oculto en un PDF. Como el motor no usa ningún modelo de lenguaje, los jailbreaks clásicos no funcionan tal cual: el riesgo real está en los datos y en las personas. De este análisis salen cinco mecanismos nuevos: detección de duplicados, caducidad de los datos, pregunta explícita de riesgo vital, congelación de pesos si fallan las métricas de equidad y doble firma para correcciones manuales grandes.

Explicabilidad en capas (Apéndice D). Una capa para la ciudadanía (aviso de uso de IA, factores que han influido y botón de revisión humana) y otra para auditoría y reguladores como la AEPD y la AESIA (gobernanza de datos, desglose de la puntuación por variable, registros inmutables y auditorías de impacto)

5. Organización del Sprint

Mantuvimos los roles del Sprint 1 porque funcionaron bien, revisamos el tablero Kanban cada 3 días y aplicamos las acciones de la retrospectiva anterior: otra persona revisaba cada sección antes de cerrarla y dejamos el último día para el repaso general. Para el Sprint 3 queremos apuntar las decisiones de cada reunión en un documento compartido y limitar la revisión de cada tarea a 15 minutos. El detalle está en la wiki (Sprint Planning, Review, Retrospective y AI Log).

6. Apéndices

- Apéndice A - Definición del proyecto 2030 v2.0
- Apéndice B - Mock-ups y Arquitectura v1.0
- Apéndice C - Personalización y Límites Éticos v1.0
- Apéndice D - Explicabilidad en Capas v1.0
- Apéndice E - Reflexión posturas macro v1.0
- Apéndice F - Robustez y Casos Límite v1.0
- Apéndice G - Análisis de riesgos a gran escala v1.0