Líneas Rojas

PrioritarIA

EIA - Anexo de líneas rojas

Índice

1. PrioritarIA nunca ordena casos de riesgo vital o sanitario. 3

2. PrioritarIA nunca decide ni deniega una ayuda por sí solo. 3

3. PrioritarIA nunca puntúa por zona, nacionalidad, canal de solicitud ni por la concesión de otra ayuda. 3

4. PrioritarIA nunca interpreta la falta de datos como menor urgencia ni penaliza automáticamente. 4

5. PrioritarIA nunca usa IA generativa ni aprende “en vivo” para puntuar. 4

Referencias 5

1. **PrioritarIA nunca ordena casos de riesgo vital o sanitario.**

Prohíbe que en un caso de violencia de género, riesgo inmediato para la vida o urgencia sanitaria espere en una cola a que le toque su turno, aunque sea una cola con prioridad.

Se considera que un caso que puede ser mortal no admite un cálculo previo ni margen de error, hay que actuar de manera inmediata. Además, una puntuación alta seguiría implicando esperar detrás de otros casos graves. Las decisiones sanitarias tampoco son competencia municipal.

Para garantizarlo los tres canales (digital, telefónico y presencial) incluyen una pregunta explícita de riesgo inmediato. Si se marca, el caso sale de la cola y se deriva ese mismo día al protocolo de emergencias, sin esperar a ningún cálculo. No se usa procesamiento automático para detectarlo, por el riesgo de falsos negativos y de manipulación. Se asume como limitación que, si alguien lo cuenta solo en observaciones, depende de que una persona lo lea.

2. **PrioritarIA nunca decide ni deniega una ayuda por sí solo.**

La puntuación no se puede convertir en una resolución, que excluya a alguien automáticamente. Tampoco se puede alterar la puntuación original del modelo para favorecer una decisión.

Es un sistema de alto riesgo y su salida es solo una recomendación técnica. La supervisión humana, además de una garantía ética, es una obligación legal. Prohibir las decisiones únicamente automatizadas con efectos jurídicos sobre la persona es un principio básico del RGPD [2][3][4].

Para garantizalo la resolución siempre tiene que estar firmada por una persona trabajadora del ayuntamiento. Si modifica el orden propuesto, debe indicar un motivo (catálogo cerrado más texto libre) y su cambio requiere una segunda firma. El registro inmutable guarda por separado la puntuación original, la posición final, el motivo y el autor. Los casos dudosos pasan siempre a revisión obligatoria.

3. **PrioritarIA nunca puntúa por zona, nacionalidad, canal de solicitud ni por la concesión de otra ayuda.**

Prohíbe que estas variables o cualquier variable de origen étnico, religión y orientación política, entren en la puntuación, ni siquiera de forma indirecta aprendida de los datos históricos.

A gran escala, un riesgo así deja de ser un error aislado y pasa a ser una desigualdad estructural. Además, la ley de igualdad de trato exige a las administraciones minimizar sesgos en los algoritmos [5].

Para ello, estas variables se recogen o se usan solo para medir la equidad, nunca para puntuar. El entrenamiento toma como referencia la necesidad acreditada y no si antes se concedió la ayuda. Los pesos solo se mueven dentro de límites fijados de antemano. Una prueba automática comprueba que el mismo expediente, por vía digital o presencial, recibe la misma puntuación.

4. **PrioritarIA nunca interpreta la falta de datos como menor urgencia ni penaliza automáticamente.**

Los campos vacíos nunca pueden valer 0 puntos, ni un documento ausente baja a alguien en la cola.

Porque quién más difícil lo tiene (sin NIE, sin nóminas, con poca competencia digital) sería quien más bajo estaría en la cola. Eso reforzaría la exclusión que el sistema pretende reducir. Además, la administración debe dar plazo para subsanar antes de resolver.

Un expediente con información incompleta no recibe puntuación: queda marcado como "información incompleta" y pasa a una persona. Se abre un plazo de subsanación, se ofrece ayuda presencial y el trabajador social puede acreditar la situación con un informe propio. Los datos que ya tiene la administración se recuperan por interoperabilidad, sin pedirlos de nuevo. Los patrones anómalos solo se marcan para revisión humana, sin penalización automática.

5. **PrioritarIA nunca usa IA generativa ni aprende "en vivo" para puntuar.**

Se prohíbe que un modelo de lenguaje lea documentos y genere datos que puntúen, que las explicaciones las redacte un modelo de IA generativa, o que los pesos cambien mientras se procesan solicitudes.

Esto se debe a que un modelo generativo puede "alucinar", no es reproducible y puede obedecer instrucciones ocultas en un documento (*prompt injection*) [6]. Un modelo que aprende en producción deja de ser determinista y no puede garantizar que dos expedientes idénticos reciban la misma puntuación, algo exigible en resoluciones administrativas [2].

La puntuación sale solo de campos estructurados contrastados con fuentes oficiales, y el texto libre no entra en el cálculo. Los pesos se ajustan offline, se validan antes de desplegarse y se congelan en producción. Las explicaciones salen de una suma aditiva exacta (valores SHAP), no de un modelo generativo [7].

Referencias

1. **BOE (2004).** *Medidas de Protección contra la Violencia de Género.* https://www.boe.es/buscar/act.php?id=BOE-A-2004-21760
2. **EU Artificial Intelligence Act.** *Artículo 14: Supervisión humana.* Artículo 14: Supervisión humana | EU Artificial Intelligence Act
3. **EUR-Lex (2016).** *Reglamento general de protección de datos.* Reglamento - 2016/679 - EN - GDPR - EUR-Lex
4. **BOE (2015).** *Ley 40/2015, de 1 de octubre, de Régimen Jurídico del Sector Público*. BOE-A-2015-10566 Ley 40/2015, de 1 de octubre, de Régimen Jurídico del Sector Público.
5. **BOE (2022).** *Ley 15/2022, de 12 de julio, integral para la igualdad de trato y la no discriminación*. BOE-A-2022-11589 Ley 15/2022, de 12 de julio, integral para la igualdad de trato y la no discriminación.
6. **OWASP (2025).** *LLM01: Prompt Injection - OWASP Gen AI Security Project*. LLM01:2025 Prompt Injection - OWASP Gen AI Security Project
7. **Lundberg, S. M., & Lee, S.-I. (2017).** *A Unified Approach to Interpreting Model Predictions*. 1705.07874