Sprint 3 - PrioritarIA

1. Qué es nuevo en este sprint

En este tercer sprint hemos reforzado PrioritarIA abordando las críticas recibidas en el debate del Sprint 2 (Apéndice A, Definición del proyecto v3.0) y hemos profundizado en las implicaciones sociales de nuestro sistema analizando los riesgos y límites del proyecto: tabla de riesgos (Apéndice B), plausibilidad (C), líneas rojas (D), emergencias (E) y rendición de cuentas y reparación (F). Además, hemos especificado usuarios, sesgos y colectivos afectados (G), y actualizado los anexos de riesgos a gran escala, explicabilidad, personalización y robustez.

2. Evolución de la especificación y respuesta al debate

Durante el debate, nos atacaron principalmente por pequeñas contradicciones entre anexos y cuestiones que seguíamos sin resolver de forma clara:

- **Revisión humana y casos dudosos**. Ahora hemos definido criterios cerrados para marcar un caso como dudoso (datos incompletos o no oficiales, saltos bruscos, incoherencias, alta incertidumbre, plazo superado), con umbrales aprobados y publicados por el órgano de baremo. Si el trabajador modifica el orden propuesto prevalece su decisión, pero con motivo registrado y una segunda firma.
- **Modelo y manipulación**. Los pesos se ajustan offline dentro de límites fijos, se validan y se congelan, por lo que en producción PrioritarIA es un sistema determinista y las explicaciones provienen de los valores SHAP. El solicitante ya no ve su posición exacta en la cola, sino su nivel de prioridad (alta, media, baja), y solo puntúan datos oficiales y verificables.
- **Equidad entre canales y reparación**. Una prueba automática comprueba que el mismo expediente recibe la misma puntuación independientemente del canal de solicitud. Si falla, se tratará como un fallo del sistema y se activará el protocolo de reparación para los afectados por el error (Apéndice F).
- **Casilla de riesgo**. La valoración de riesgo urgente la realiza un profesional en un plazo definido. Si no se puede confirmar, el caso sigue en su posición original sin penalización, y solo se penalizará ante falsedad documental.

3. Análisis de riesgos y límites del proyecto

Tabla de riesgos (Apéndice B). Recogemos 8 riesgos principales detallando su gravedad, la probabilidad de que suceda, y las acciones de prevención y contingencia. Los más graves (categorizados como críticos) son los sesgos históricos, la dilación de casos de riesgo vital y la fuga de datos. Los identificados como más probables son la brecha digital y el sesgo de automatización, por lo que son los que más acción de prevención han recibido dentro del diseño de nuestro sistema.

Plausibilidad (Apéndice C). Hemos identificado tres puntos frágiles en nuestro sistema: la interoperabilidad de registros públicos (depende de eIDAS2 y de los datos de alto valor hasta 2028-2030), el ajuste offline con determinismo en producción y la explicabilidad fiel con SHAP. El que genera mayor duda es el primero porque depende de otras

administraciones, por lo que si falla el sistema pasa a “información incompleta” y a revisión humana (no a una priorización errónea).

Líneas rojas (Apéndice D). Se especifica que PrioritarIA nunca ordena casos de riesgo vital, concede o deniega ayudas por sí solo, puntúa por zona, nacionalidad, canal de solicitud o por otra ayuda concedida, interpreta la falta de datos como menor urgencia, ni usa IA generativa o LLMs.

Emergencias (Apéndice E). Se establece que pueden ordenar la parada total del sistema el CISO o la Dirección de Servicios Sociales. Se para el sistema si hay brecha de seguridad, si la desviación de equidad supera el 15% (en grupos de al menos 30 expedientes) o si las conexiones impiden puntuar a más del 30% de usuarios. El procedimiento consiste en congelar la cola, pasar a solo lectura y a tramitación manual, auditar y notificar a la AESIA y a AEPD si hay fuga de datos, y reanudar el sistema solo con autorización del órgano de baremo.

Rendición de cuentas (Apéndice F). Se puede realizar una reclamación por los tres canales (online, telefónico o presencial), teniendo el derecho a una explicación de la resolución sin necesidad de reclamar antes. Siempre revisa una persona. Hay cuatro vías de reparación: reversión, compensación (sin asegurar pago automático), corrección (también en otros programas de ayudas) y prevención. Responde el ayuntamiento, y el proveedor deberá corregir los fallos técnicos del sistema.

4. Usuarios, sesgos y colectivos afectados (Apéndice G)

Los usuarios directos son los solicitantes de las ayudas y los trabajadores sociales. Los indirectos son los menores a cargo, personas mayores dependientes o convivientes que no rellenan formularios. Observamos que hay una fuerte asimetría, ya que las familias solicitantes se encuentran en situación de necesidad y dependen por completo de la resolución de la administración, por eso el sistema nunca decide solo y la responsabilidad cae sobre el ayuntamiento. Analizamos tres colectivos vulnerables: personas mayores (brecha digital), población migrante (sin NIE o nóminas) y hogares monoparentales de renta muy baja. Cuando se cruzan, la dificultad se multiplica, por ello los campos vacíos nunca restan y un trabajador social revisa dichos casos. Frente al sesgo, en los datos actuamos con auditorías y entrenamiento con necesidad acreditada, en el modelo con pesos acotados, offline y congelados, y en el producto mediante los tres canales de solicitud y especificando el nivel de riesgo en vez de la posición exacta.

5. Organización del Sprint

Seguimos manteniendo los mismos roles que el Sprint 1 ya que funcionan bien y el tablero Kanban con revisiones frecuentes para que las entregas sean graduales y no se acumule todo para el final. De la retrospectiva del Sprint 2, hemos creado un documento compartido de notas diarias donde apuntamos las decisiones de cada reunión, y aumentamos el número de reuniones cortas para que todo el equipo siguiera el proyecto a la vez y ningún rol quedase descolgado.

Para el Sprint 4, hemos definido 3 mejoras: limitar a 20 minutos los debates teóricos, congelar el formato 48 horas antes de la entrega para dedicarlas a la revisión cruzada, y hacer un ensayo del pitch con cronómetro. Todo está detallado en la wiki del proyecto.

6. Apéndices

- Apéndice A - Definición del proyecto 2030 v3.0
- Apéndice B - Tabla de riesgos v1.0
- Apéndice C - Plausibilidad v1.0
- Apéndice D - Líneas rojas v1.0
- Apéndice E - Emergencias v1.0
- Apéndice F - Rendición de cuentas y reparación v1.0
- Apéndice G - Usuarios, sesgos y colectivos afectados v1.0
- Actualizados a v2.0: análisis de riesgos a gran escala, explicabilidad en capas, personalización, robustez y casos límite