Emergencias y Paradas del Sistema

PrioritarIA

EIA - Emergencias y Paradas del Sistema

Índice

1. Quién puede parar el sistema **3**
2. Cuándo se activa **3**
3. Cómo es el procedimiento **4**
Referencias **5**

1. Quién puede parar el sistema

El reglamento de IA de la Unión Europea requiere que las personas encargadas de la supervisión humana puedan interrumpir un sistema de alto riesgo mediante un "botón de parada" o "*kill switch*", o algún procedimiento equivalente que lleve el sistema a un estado seguro [1]. Adicionalmente, el ayuntamiento, responsable del despliegue del producto, deberá suspender el uso del sistema de PrioritarIA si considera que presenta un riesgo grave, y deberá informar al proveedor y a la autoridad de vigilancia del mercado [2].

La autoridad para ordenar la parada total del sistema recae sobre dos figuras principales, que pueden actuar de forma independiente en caso de urgencia extrema, pero siempre deberán notificarse mutuamente:

- **Responsable de Seguridad de la Información (CISO) del Ayuntamiento**: figura que el Esquema Nacional de Seguridad establece frente a amenazas técnicas, de ciberseguridad o fugas de datos [3].
- **Dirección del Área de Servicios Sociales**: órgano responsable del sistema según la Ley 40/2015 para la actuación administrativa automatizada ante desviaciones éticas o sociales y fallos graves en la ordenación que pueden perjudicar gravemente a la ciudadanía [4].

Cualquier técnico o trabajador social puede activar el bloqueo preventivo (descrito en el apartado 3) pero nunca ejecutar una parada total. El proveedor tecnológico debe avisar al ayuntamiento si detecta un defecto crítico en el sistema y corregirlo, pero no tiene la potestad de parar ni reanudar el sistema por su cuenta. Las autoridades competentes (AEPD, AESIA o un órgano judicial) pueden pedir la parada. Además, quien active una parada por una causa razonable y justificada, aunque después resulte innecesaria, no sufrirá consecuencias por ello.

2. Cuándo se activa

El sistema se detendrá de forma inmediata si se cumple alguna de las siguientes situaciones:

- **Vulneración de la seguridad crítica:** se refiere a la detección de una brecha de datos personales, acceso no autorizado al sistema o un intento de alteración maliciosa de los pesos del modelo. En este caso se activarán las alarmas del Esquema Nacional de Seguridad [3].
- **Desviación grave del algoritmo de ordenación:** si en las auditorías periódicas o mediante las alertas automatizadas del sistema se detecta una desviación repentina en la equidad entre los colectivos (por ejemplo, nacionalidad o canal de entrada) que supere un umbral de tolerancia del 15%. Para evitar falsas alarmas, solo se comparan casos de necesidad similar y grupos de al menos 30 expedientes. Este umbral responde a la obligación de minimizar sesgos en los algoritmos de las administraciones [5] y la concreción de la contingencia del riesgo de sesgos históricos (R1) [6]. También se detiene el sistema si los valores SHAP que genera no coinciden con los baremos aprobados, o si falla alguna de las pruebas automáticas de coherencia, que son garantías de nuestras líneas rojas 3 y 5 [7].

- **Fallo de conexión con sistemas externos de datos:** corresponde a la caída prolongada de los nodos de conexión con otras administraciones (SEPE, Padrón y otros registros) que impida el cálculo de la puntuación en más del 30% de los usuarios. Esta fragilidad técnica ya la identificamos en el anexo de plausibilidad [8] y causaría que se generase una cola masiva de expedientes en "información incompleta".

Municipios pequeños. El sesgo del modelo no se vigila ayuntamiento a ayuntamiento, los pesos se ajustan una sola vez para el producto general, con datos auditados de muchos ayuntamientos, y la desviación entre grupos se mide sobre esa muestra conjunta. Las métricas locales (resoluciones y modificaciones del personal) solo se calculan e informan para grupos de al menos 30 expedientes, para no dar alarmas sin datos suficientes ni identificar a personas, y la parada automática por desviación del 15% se aplica solo a esos grupos. En los grupos menores se acumulan ventanas más largas, por ejemplo 12 meses. Como el volumen es bajo, la muestra mensual de revisión es mayor en estos municipios.

3. Cómo es el procedimiento

Ante la detección de alguna de las situaciones mencionadas anteriormente, se seguirá el siguiente procedimiento de actuación inmediata:

1. **Alerta y bloqueo preventivo:** cualquier técnico o trabajador social que detecte un fallo crítico en el sistema debe notificarlo al sistema interno (mediante un botón de alerta en el panel de control). Así, el sistema suspenderá temporalmente la reordenación automática de nuevas solicitudes y congelará la cola en el último estado "seguro".
2. **Notificación a la dirección:** el sistema enviará una alerta automática prioritaria al CISO y a la Dirección de Servicios Sociales, especificando la métrica o el umbral que ha provocado la alerta.
3. **Activación de la parada total ("*Kill Switch*"):** el responsable autorizado accede al panel de administración y ejecuta la "Parada de Emergencia". PrioritarIA pasa a modo de solo lectura, y los trabajadores sociales pasan a tramitar los expedientes de forma manual y, si es inviable, se ordenará por fecha de entrada revisando primero los indicios de urgencia.
4. **Auditoría y notificación:** se inicia un diagnóstico con los motivos de la parada. Si se trata de un incidente grave, se informa a la AESIA y al proveedor, según el reglamento de IA [2]. Si ha habido una fuga de datos personales, se notifica a la AEPD en el plazo máximo de 72 horas desde que se conoce la fuga y se avisará a las personas afectadas sin dilación cuando el riesgo de vulneración de sus derechos sea alto [9]. Dichas personas tendrán a su disposición mecanismos de reversión, corrección y compensación por daños causados [10].
5. **Reanudación:** el sistema solo se reiniciará cuando se reparen los errores y el órgano municipal que aprueba el baremo autorice el despliegue de la nueva versión validada. La última versión validada se mantendrá como punto de retorno.

Referencias

1. **Reglamento (UE) 2024/1689 (Ley de IA).** *Artículo 14.4.e: Supervisión humana y procedimiento de parada hacia un estado seguro.* https://artificialintelligenceact.eu/es/article/14/
2. **Reglamento (UE) 2024/1689 (Ley de IA).** *Artículo 26.5: Obligación del responsable del despliegue de suspender el uso e informar al proveedor y a la autoridad de vigilancia del mercado.* https://artificialintelligenceact.eu/article/26/
3. **Real Decreto 311/2022, de 3 de mayo.** *Esquema Nacional de Seguridad en el ámbito de la Administración Electrónica.* https://www.boe.es/buscar/act.php?id=BOE-A-2022-7191
4. **Ley 40/2015, de 1 de octubre, de Régimen Jurídico del Sector Público.** *Artículo 41: Actuación administrativa automatizada y órgano responsable.* https://www.boe.es/buscar/act.php?id=BOE-A-2015-10566
5. **Ley 15/2022, de 12 de julio, integral para la igualdad de trato y la no discriminación.** *Artículo 23.* https://www.boe.es/buscar/act.php?id=BOE-A-2022-11589
6. **PrioritarIA**. *Anexo - Tabla de Riesgos, v1.0, riesgo R1 (sesgos históricos).*
7. **PrioritarIA**. *Anexo - Líneas Rojas, v1.0, líneas rojas 3 (no puntuar por zona, nacionalidad ni canal de solicitud) y 5 (no IA generativa ni aprendizaje en vivo).*
8. **PrioritarIA**. *Anexo - Plausibilidad, v1.0, apartado 2.1 (interoperabilidad de registros públicos).*
9. **Reglamento (UE) 2016/679 (RGPD).** *Artículos 33 y 34: notificación de violaciones de seguridad a la autoridad de control y a los afectados.* https://eur-lex.europa.eu/eli/reg/2016/679/oj
10. **PrioritarIA**. *Anexo - Rendición de cuentas, reclamaciones y reparación, apartado 3 (formas de reparación).*